

Aspect Is Not You Need: No-aspect Differential Sentiment Framework for Aspect-based Sentiment Analysis

Phạm Đức Thế^{1,2},
Nguyễn Văn Kiệt^{1,3}

¹Đại Học Công Nghệ Thông Tin – Đại Học Quốc Gia TP.HCM, Việt Nam

²{19522253}@gm.uit.edu.vn

³{kietnv}@uit.edu.vn

Tóm Tắt Nội Dung


Phân tích cảm xúc dựa trên khía cạnh (ABSA) là một tác vụ phân loại cảm xúc chi tiết. Hầu hết các nỗ lực gần đây đều áp dụng pre-trained model để phân loại các câu với các khía cạnh. Tuy nhiên, aspect sentiment bias từ pre-trained model mang lại một số nhiễu cho tác vụ ABSA. Bên cạnh đó, các phương pháp truyền thống sử dụng cross-entropy loss khó tìm ra mối liên hệ tiềm năng giữa các trạng thái cảm xúc. Trong bài báo này, tác giả phân tích tác vụ ABSA từ một góc độ nhận thức mới: con người thường có thể đánh giá cảm xúc của một khía cạnh ngay cả khi họ không biết khía cạnh đó là gì. Hơn nữa, đối với con người, việc phân biệt cảm xúc positive và negative dễ dàng hơn những cảm xúc khác vì đó là hai cảm xúc trái ngược nhau. Để đạt được điều này, tác giả đề xuất no-aspect differential sentiment (NADS) framework cho tác vụ ABSA. Đầu tiên, tác giả thiết kế một no-aspect template bằng cách thay thế aspect đó bằng một ký tự special unbiased để loại bỏ sentiment bias và obtain a stronger representation. Để có được những lợi ích tốt hơn từ template, tác giả áp dụng contrastive learning giữa no-aspect template và original sentence. Sau đó, tác giả đề xuất một differential sentiment loss thay vì cross-entropy loss để phân loại cảm xúc tốt hơn bằng cách phân biệt khoảng cách khác nhau giữa các cảm xúc. Mô hình đề xuất của tác giả là một general framework và có thể được kết hợp với hầu hết các phương pháp ABSA truyền thống. Các thực nghiệm trên SemEval 2014 cho thấy rằng framework của tác giả vẫn có thể dự đoán cảm xúc của khía cạnh ngay cả khi chúng ta không biết khía cạnh đó là gì. Hơn nữa, NADS framework của tác giả thúc đẩy ba phương pháp ABSA điển hình và đạt được hiệu suất state-of-the-art (SOTA).

1 Introduction

Phân tích cảm xúc dựa trên khía cạnh (Aspect-based sentiment analysis – ABSA) (Jiang et al.,

2011) nhằm mục đích xác định các trạng thái của cảm xúc (tức là *tiêu cực (negative)*, *neutral (neutral)* hoặc *tích cực (positive)*) của từng *khía cạnh (aspect)* cụ thể trong một đoạn văn bản (Hou et al., 2021; Dai et al., 2021; Li et al., 2021). Ví dụ: “The food is great, but the service is terrible”, cảm xúc đối với “food” là positive trong khi với “service” là negative. Chúng ta cần dự đoán cảm xúc của các aspect term khác nhau trong một sentence.

Các công trình trước đây thường sử dụng pre-trained model để trích xuất embedding của phần nổi của sentence và aspect term. Bằng cách này, cơ chế attention trong pre-trained model sẽ tăng cường kết nối giữa khía cạnh và ngữ cảnh của nó (Tang et al., 2015; Song et al., 2019). Kết quả thực nghiệm xác minh hiệu suất hấp dẫn của nó. Tuy nhiên, pre-trained model trên *kho ngữ liệu thô quy mô lớn (large-scale raw corpora)* có xu hướng internalize aspects’ intrinsic attributes (Huang et al., 2020) và mang lại một số nhiễu cho tác vụ ABSA. Ví dụ: “Desserts include flan and sopaipillas”, một mô hình điển hình BERT-SPC (Song et al., 2019) dựa trên BERT (Devlin et al., 2019) có xu hướng phân loại cảm xúc đối với “Desserts” là positive, trong khi label là neutral. Điều này là do trong pre-trained corpora, “Desserts” thường xuất hiện với những từ chứa cảm xúc positive, khiến từ “Desserts” cũng thể hiện cảm xúc positive. Hơn nữa, các phương pháp phân loại văn bản truyền thống sử dụng cross-entropy loss có một số thiếu sót. Một mặt, cross-entropy loss suffers from lacking of robustness đối với các nhãn nhiễu (Zhang and Sabuncu, 2018) và possibility of poor margins (Elsayed et al., 2018). Mặt khác, cross-entropy loss bỏ qua các mối quan hệ tiềm năng giữa các trạng thái cảm xúc khác nhau. Trong khi đó, non-smooth anisotropic semantic space được tạo ra bởi pre-trained model (Li et al., 2020) cũng gây khó khăn trong việc phân biệt các mối quan hệ tiềm năng giữa các cảm xúc.



Hình 1: Human performance on the ABSA task.

Để giải quyết những vấn đề này, tác giả phân tích tác vụ ABSA từ góc độ nhận thức của con người. Mọi người thường chú ý đến learning strategy và feature representation trong nhiều tác vụ NLP, nhưng bỏ qua việc tổ chức các khái niệm giữa con người và trí tuệ nhân tạo. Về mặt trực giác, con người vẫn có thể thực hiện tốt tác vụ ABSA mà không cần biết ý nghĩa của khía cạnh. Như trong Hình 1, “*I had a delicious shrimp.*”, có thể chúng ta không biết “*shrimp*” là gì (nó là một loại thực phẩm), chúng ta cũng có thể dễ dàng phân loại cảm xúc của từ này là positive. Bởi vì chúng ta có thể đánh giá cảm xúc của khía cạnh thông qua ngữ cảnh của nó. Hơn nữa, trong nhận thức của con người, “*positive*” và “*negative*” là hai cảm xúc trái ngược nhau và “*neutral*” nằm ở giữa. Khoảng cách giữa “*positive*” và “*neutral*” rõ ràng gần hơn so với “*positive*” và “*negative*”.

Lấy cảm hứng từ nhận thức của con người, tác giả đề xuất *cảm xúc khác biệt không có khía cạnh* (no-aspect differential sentiment – NADS) framework. Đầu tiên, tác giả thiết kế một no-aspect template bằng cách thay thế aspect term trong câu bằng ký tự sentiment unbiased đặc biệt “*< aspect >*” và sử dụng contrastive learning giữa no-aspect template và original sentence. Bằng cách này, chúng ta không chỉ có thể loại bỏ sentiment bias trong original sentence, mà còn học được nhiều sentence patterns hơn như thể hiện trong Hình 1 để nâng cao robustness cho framework của tác giả. Hơn nữa, nó giúp NADS framework của tác giả đánh giá cảm xúc của khía cạnh mà không cần biết ý nghĩa cụ thể của nó, giống như con người. Sau đó, để giảm sự mất mát ngữ nghĩa do ký tự đặc biệt “*< aspect >*” gây ra, tác giả sử dụng masked aspect prediction để giữ thông tin ngữ nghĩa ban đầu. Hơn nữa, tác giả thiết kế differential sentiment loss để tìm ra khoảng cách khác nhau giữa các cảm xúc và phân biệt tốt hơn các cảm xúc khác nhau. Những đóng góp chính của tác giả là:

- Tác giả đề xuất một no-aspect template và

sử dụng phương pháp no-aspect contrastive learning để xem xét phạm vi rộng hơn của sentence patterns và loại bỏ sentiment bias trong việc aspect embedding. Điều này cũng cho phép mô hình của tác giả dự đoán cảm xúc của khía cạnh mà không cần biết khía cạnh đó là gì, giống như con người.

- Tác giả thiết kế differential sentiment loss để giúp phân biệt rõ hơn các khoảng cách khác nhau giữa các cảm xúc. Hơn nữa, differential sentiment loss của tác giả có thể làm cho các mẫu có cùng cảm xúc càng gần càng tốt và các mẫu có cảm xúc khác nhau càng xa càng tốt.
- Các thực nghiệm trên SemEval 2014 cho thấy mô hình của tác giả nâng cao hiệu suất của ba phương pháp ABSA điển hình và đạt được SOTA mới. Ngoài ra, các thực nghiệm trên aspect robustness test set ARTS cho thấy mô hình NADS của tác giả có thể cải thiện đáng kể robustness của mô hình.

2 Related Work

Phân tích cảm xúc dựa trên khía cạnh là một tác vụ phân loại cảm xúc chi tiết. Gần đây, một số công trình về ABSA đã tập trung vào việc leveraging syntactic knowledge thông qua *cây cú pháp* (syntactic trees). (Wang et al., 2020) đã định hình lại syntactic tree với các aspect term là trung tâm và sử dụng relational graph attention network để mã hóa cấu trúc cây mới cho dự đoán cảm xúc. (Hou et al., 2021) đã kết hợp các mối quan hệ phụ thuộc từ các phân đoạn khác nhau trước khi áp dụng GNN trên biểu đồ kết quả.

Một xu hướng khác sử dụng các cơ chế attention khác nhau để tìm mối quan hệ ngữ nghĩa của một khía cạnh và ngữ cảnh của nó (Tan et al., 2019; Li et al., 2018; Fan et al., 2018; Huang et al., 2018). Cơ chế attention giúp tập trung vào ngữ cảnh liên quan đến khía cạnh và che chắn ngữ cảnh không liên quan. Bên cạnh đó, một số công trình đã cố gắng tích hợp syntax tree và cơ chế attention. Công trình gần đây nhất (Li et al., 2021) đã sử dụng cơ chế mutual biaffine attention để kết hợp thông tin cú pháp và thông tin ngữ nghĩa từ syntactic tree.

Song song đó, pre-trained language model BERT (Devlin et al., 2019) đã đạt được hiệu suất đáng kể trong nhiều tác vụ NLP. Các thực nghiệm cho thấy rằng việc sử dụng BERT trong ABSA có thể đạt được kết quả tốt hơn (Li et al., 2021; Zhang



Hình 2: (a) and (b) are the causal graphs for traditional ABSA methods and our NADS. A : aspect terms. C : context. M : the fusing information of aspect and context. Y : sentiment of the aspect. a^* : the special character without sentiment bias.

et al., 2019) so với việc sử dụng các static word embedding như Word2vec (Mikolov et al., 2013) và GloVe (Pennington et al., 2014). Tuy nhiên, (Wang et al., 2021) đã chỉ ra rằng sentiment bias về khía cạnh gây ra bởi pre-trained model có thể làm rối loạn tác vụ ABSA. Họ sử dụng external sentiment knowledge SentiWordNet (Esuli and Sebastiani, 2006) để trích xuất ba loại cảm xúc trước đó cho các aspect term. Sau đó, họ đề xuất một adversarial network để loại bỏ cảm xúc trước đó về các aspect term. Tuy nhiên, người ta không biết liệu trạng thái cảm xúc khía cạnh được gán nhãn từ SentiWordNet có phù hợp với sentiment bias trong pre-trained model hay không. Ngoài ra, các công trình trước đây sử dụng cross-entropy loss cũng bỏ qua mối liên hệ tiềm năng giữa các trạng thái cảm xúc khác nhau.

Trong bài báo này, tác giả đề xuất một no-aspect template và sử dụng phương pháp contrastive learning để loại bỏ sentiment bias và học nhiều sentence patterns hơn để cải thiện robustness của mô hình. Hơn nữa, tác giả thiết kế differential sentiment loss để phân biệt rõ hơn khoảng cách khác nhau giữa các cảm xúc và cluster cảm xúc giống nhau.

3 Preliminaries

Trong phần này, tác giả sử dụng causal inference (Pearl et al., 2000; Robins, 2003) để minh họa cơ sở lý thuyết của framework. Tác giả minh họa các phương pháp ABSA truyền thống và NADS framework của tác giả bằng cách sử dụng *biểu đồ nhân quả (causal graph)* được mô tả trong Hình 2. Biểu đồ phản ánh mối quan hệ nhân quả giữa các biến và tác giả sử dụng “ \rightarrow ” biểu thị tác động trực tiếp. Đối với tác vụ ABSA, các yếu tố ảnh hưởng đến dự đoán cảm xúc bao gồm specific aspect term A mà chúng ta cần dự đoán và ngữ cảnh của khía cạnh C . Cả A và C đều quan trọng đối với tác vụ ABSA vì C chứa thông tin cảm xúc và chúng ta

cần biết khía cạnh A để dự đoán cảm xúc.

Trong biểu đồ nhân quả của các phương pháp truyền thống như thể hiện trong Hình 2 (a), ngữ cảnh và khía cạnh nắm bắt ảnh hưởng trực tiếp của cảm xúc thông qua $C \rightarrow Y$ và $A \rightarrow Y$. Thông tin hợp nhất ghi lại ảnh hưởng gián tiếp của A và C lên Y thông qua M , tức là $A, C \rightarrow M \rightarrow Y$. Kết quả dự đoán mà Y sẽ nhận được nếu A được đặt thành a và C được đặt thành c là:

$$Y_{a,c} = Y(A = a, C = c, M = m) \quad (1)$$

trong đó $m = M_{a,c}$ là thông tin về sự hợp nhất của khía cạnh a và ngữ cảnh c . Theo công thức này, các phương pháp truyền thống cân nhắc tốt vai trò của khía cạnh và ngữ cảnh của nó trong tác vụ ABSA. Tuy nhiên, trong nhận thức của con người, ý nghĩa cụ thể của khía cạnh không ảnh hưởng đến đánh giá của mọi người về cảm xúc của nó. Các phương pháp truyền thống đã bỏ qua aspect sentiment bias khiến khía cạnh có tác động trực tiếp đến kết quả dự đoán Y thông qua $A \rightarrow Y$. Nó có thể khiến các mô hình ABSA bị ảnh hưởng bởi mối tương quan giả giữa khía cạnh và cảm xúc, do đó không thực hiện được lý luận hiệu quả.

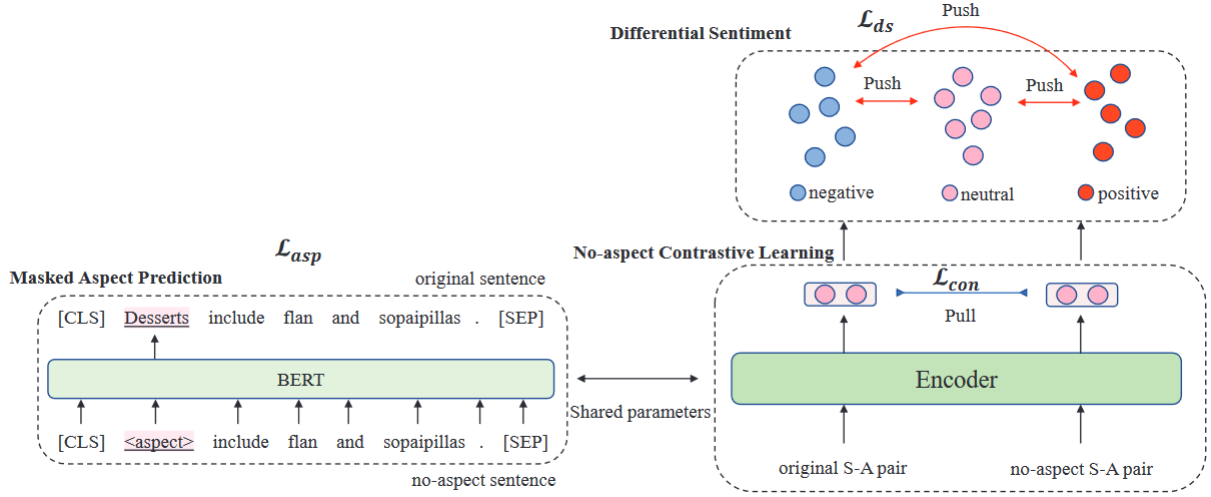
Trong NADS framework, tác giả đề xuất loại trừ ảnh hưởng aspect sentiment bias đối với $A \rightarrow Y$ trong ABSA như thể hiện trong Hình 2 (b). Tác giả sử dụng một ký tự đặc biệt “ $< aspect >$ ” không sentiment bias để thay thế khía cạnh ban đầu trong câu và sử dụng masked aspect prediction để giữ thông tin ngữ nghĩa ban đầu của câu. Tác giả nhận được dự đoán cảm xúc Y là:

$$Y_{a^*,c} = Y(A = a^*, C = c, M = m^*) \quad (2)$$

trong đó $a^* = “< aspect >”$ và $m^* = M_{a^*,c}$. Bằng cách này, tác giả loại bỏ tác động trực tiếp của aspect sentiment bias đối với kết quả dự đoán và giữ lại thông tin ngữ nghĩa ban đầu.

4 Proposed NADS

Trong tác vụ ABSA, cho một sentence $S = \{w_1, w_2, \dots, w_\tau, \dots, w_{\tau+t}, \dots, w_n\}$ và một aspect term $A = \{w_\tau, w_{\tau+1}, \dots, w_{\tau+t-1}\}$, mục đích là để dự đoán trạng thái cảm xúc của A trong S . Như thể hiện trong Hình 3, NADS framework của tác giả bao gồm ba phần. Trước tiên, tác giả đề xuất no-aspect template và sử dụng phương pháp contrastive learning giữa no-aspect template và original sentence để xem xét phạm vi rộng hơn



Hình 3: An overview of proposed no-aspect differential sentiment (NADS) framework.

của sentence patterns và loại bỏ sentiment bias trong việc aspect embedding. Sau đó, để làm cho câu có các ký tự đặc biệt “< aspect >” mà vẫn giữ được thông tin ngữ nghĩa ban đầu, tác giả sử dụng masked aspect prediction. Cuối cùng, tác giả thiết kế differential sentiment loss để học khoảng cách khác nhau giữa các trạng thái cảm xúc. Tác giả trình bày chi tiết về NADS được đề xuất.

4.1 No-aspect Contrastive Learning

Đối với mỗi cặp $\{S, A\}$, tác giả sử dụng một ký tự đặc biệt “< aspect >” không sentiment bias để thay thế toàn bộ aspect term A trong câu. Tác giả biểu thị no-aspect template là T :

$$T = \text{Replace}(\{S|A = a\}, < \text{aspect} >) \quad (3)$$

Để sử dụng tốt hơn thông tin từ no-aspect template và regularize pre-trained anisotropic embedding space, tác giả sử dụng phương pháp contrastive learning giữa no-aspect template và original sentence. Cụ thể, đối với mỗi cặp sentence-aspect (s_i, a_i) , ta biểu thị positive sentence là:

$$s_i^+ = T_i \quad (4)$$

trong đó T_i là no-aspect template của s_i . Do đó, chúng ta nhận được một positive instance $(s_i^+, < \text{aspect} >)$ cho (s_i, a_i) . Tác giả có được feature representation cho từng cặp sentence-aspect và positive instance thông qua bộ mã hóa $f_\theta(\cdot)$:

$$h_i = f_\theta(s_i, a_i) \quad (5)$$

$$h_i^+ = f_\theta(s_i^+, < \text{aspect} >) \quad (6)$$

trong đó h_i và h_i^+ biểu thị feature representation của cặp original sentence-aspect và positive instance. Trong NADS framework, tác giả sử dụng BERT để embedding từng cặp sentence-aspect bằng cách nhập phần nổi của aspect term và sentence. Đối với các mô hình khác, tác giả sử dụng các phương pháp của chúng làm bộ mã hóa để nhận được embedding cho từng cặp (s_i, a_i) . Tác giả biểu thị tất cả các câu khác trong mini-batch là các negative instance, do đó, contrastive loss là:

$$\mathcal{L}_{con} = -\log \frac{e^{\text{sim}(h_i, h_i^+)/\tau}}{\sum_{j=1}^N e^{\text{sim}(h_i, h_j^+)/\tau}} \quad (7)$$

trong đó τ là temperature hyperparameter và $\text{sim}(\cdot)$ là cosine similarity. N là batch size.

Bằng cách so sánh original sentence với no-aspect template, tác giả loại bỏ sentiment bias gây ra bởi các aspect term trong original sentence và không chỉ học thông tin của một sentence mà còn cả thông tin của một nhóm sentence patterns. Điều này giúp tác giả cải thiện robustness của mô hình. Hơn nữa, contrastive learning giúp chúng ta regularize pre-trained anisotropic embedding space để chuẩn bị cho differential sentiment loss.

4.2 Masked Aspect Prediction

Trong phần 4.1, tác giả sử dụng “< aspect >” để xây dựng no-aspect template. Tuy nhiên, tác giả nghĩ rằng việc sử dụng trực tiếp một ký tự đặc biệt “< aspect >” không tồn tại trong pre-trained model có thể gây ra rắc rối cho việc lưu giữ thông tin ngữ nghĩa. Do đó, tác giả sử dụng masked aspect prediction cho các ký tự đặc biệt “< aspect >” để giữ nguyên ngữ nghĩa. Cụ

thể, tác giả che các khía cạnh bằng cách sử dụng “< aspect >” và dự đoán các original aspect term ở vị trí của “< aspect >” trong ABSA training dataset của tác giả. Theo (Hong et al., 2021), mục đích của tác giả là huấn luyện cách embedding “< aspect >” để giữ đầy đủ thông tin ngữ nghĩa. Đối với NADS framework, tác giả biểu thị việc embedding vị trí “< aspect >” là $h_{[<asp>]}$. Tác giả cung cấp $h_{[<asp>]}$ vào một softmax layer để dự đoán original aspect:

$$\hat{Y}^a = \text{softmax}(W_1 h_{[<asp>]} + b_1) \quad (8)$$

trong đó W_1 và b_1 là các trainable parameter, \hat{Y}^a cho biết xác suất dự đoán của aspect word tại vị trí của nó. Tác giả nhận masked aspect prediction loss thông qua cumulative of log-likelihood đối với các dự đoán của từng vị trí “< aspect >”:

$$\mathcal{L}_{asp} = - \sum \log p(\hat{Y}^a) \quad (9)$$

Đặc biệt, tác giả chỉ dự đoán vị trí của “< aspect >” trong câu. Masked aspect prediction giúp chúng ta giữ lại thông tin ngữ nghĩa ban đầu của câu sau khi thay thế khía cạnh.

4.3 Differential Sentiment Loss

Sau khi regularizing pre-trained anisotropic embedding space bằng cách sử dụng phương pháp contrastive learning giữa original template và no-aspect template, tác giả thiết kế differential sentiment loss để phân biệt tốt hơn các cảm xúc khác nhau. Đầu tiên, tác giả embedding labels của tác giả vào cùng một kích thước của h_i . Tác giả chuyển đổi các nhãn cảm xúc positive, neutral và negative thành các label embedding $L = \{l_{pos}, l_{neu}, l_{neg}\}$. Khoảng cách giữa cặp sentence-aspect embedding h_i và label embedding l_i là:

$$d(h_i, l_i) = 1 - \frac{h_i^\top l_i}{\|h_i\| \cdot \|l_i\|} \quad (10)$$

Đối với mỗi cặp sentence-aspect embedding h_i , khoảng cách giữa h_i và label l_i của nó phải gần hơn so với các label embedding khác trong L . Do đó, tác giả sử dụng triplet loss để làm cho h_i gần hơn với right label embedding l_i và xa hơn với các label embedding khác. Đối với mỗi h_i , positive instance là label embedding l_i và các negative instance là các label embedding khác trong L . Hơn nữa, trong nhận thức của con người, khoảng cách giữa các cảm xúc khác nhau là khác nhau. Do đó, tác giả đặt

một specific margin cho từng negative instance để phân biệt rõ hơn khoảng cách khác nhau giữa các cảm xúc khác nhau. Differential sentiment loss của tác giả là:

$$\mathcal{L}_{ds} = \sum_{l'_i \in L, l'_i \neq l_i} \max(d(h_i, l_i) - d(h_i, l'_i) + m(l_i, l'_i), 0) \quad (11)$$

trong đó $m(l_i, l'_i)$ là specific margin cho label l_i và l'_i . Theo nhận thức của con người, tác giả biểu thị rằng cảm xúc positive và negative nên có cùng khoảng cách với cảm xúc neutral và khoảng cách giữa positive và negative là xa hơn. Do đó, tác giả đặt $m(pos, neu) = m(neg, neu)$ và $m(pos, neg) > m(pos, neu)$ trong mô hình của tác giả. So với cross-entropy loss, differential sentiment loss của tác giả có thể phân loại cảm xúc tốt hơn thông qua việc phân biệt sự khác nhau giữa các cảm xúc. Hơn nữa, differential sentiment loss của tác giả có thể cùng train model và label embeddings, đồng thời làm cho framework của tác giả hội tụ nhanh hơn.

Để đánh giá trạng thái cảm xúc của cặp sentence-aspect, tác giả sử dụng cosine similarity để xây dựng scoring function:

$$S(h, l) = \frac{h^\top l}{\|h\| \cdot \|l\|} \quad (12)$$

trong đó h là embedding của cặp sentence-aspect và l là embedding của label. Tác giả lấy l với score lớn nhất làm kết quả dự đoán.

Mục tiêu huấn luyện của tác giả là minimize total objective function:

$$\mathcal{L} = \mathcal{L}_{ds} + \lambda_1 \mathcal{L}_{con} + \lambda_2 \mathcal{L}_{asp} \quad (13)$$

trong đó λ_1 và λ_2 là trọng số của contrastive learning loss và masked aspect prediction loss.

5 Experiments

5.1 Datasets

Tác giả đánh giá mô hình của mình trên hai ABSA task public datasets: Restaurant và Laptop từ SemEval 2014 Task 4 (Pontiki et al., 2014). Tác giả xóa một số ví dụ có nhãn trạng thái cảm xúc “conflict” trong các bài đánh giá. Bảng 1 cho thấy thống kê của các bộ dữ liệu này.

5.2 Baseline Methods

Tác giả so sánh NADS của tác giả với các SOTA baselines. Các mô hình được mô tả như sau.

Dataset	Division	#Pos	#Neu	#Neg
Laptop	Train	976	455	851
	Test	337	167	128
Restaurant	Train	2164	637	807
	Test	727	196	196

Bảng 1: Statistics on two datasets of ABSA.

- 1) **BERT-SPC** (Song et al., 2019) sử dụng BERT để mã hóa cặp sentence-aspect thành: “[CLS] sentence [SEP] aspect [SEP]” và nhận được embedding “[CLS]”. NADS framework của tác giả sử dụng BERT-SPC làm bộ mã hóa.
- 2) **AEN+BERT** (Song et al., 2019) sử dụng BERT và một số attention layer để mã hóa cặp sentence-aspect. Embedding của sentence và embedding của aspect thu được tương ứng.
- 3) **CapsNet+BERT** (Jiang et al., 2019) kết hợp BERT và capsule networks trong ABSA.
- 4) **BERT-ADA** (Rietzler et al., 2020) sử dụng domain data để nâng cao BERT và sau đó sử dụng task data để thực hiện supervised fine-tuning.
- 5) **SDGCN+BERT** (Zhao et al., 2020) sử dụng graph convolution network cho các câu có nhiều khía cạnh.
- 6) **R-GAT+BERT** (Wang et al., 2020) đề xuất aspect-oriented tree và mã hóa dependency trees mới bằng GAT quan hệ.
- 7) **DGEDT+BERT** (Tang et al., 2020) đề xuất một mutual biaffine module để cùng xem xét representations learned từ Transformer và GNN model trên dependency tree.
- 8) **DualGCN + BERT** (Li et al., 2021) sử dụng dependency tree để trích xuất thông tin cú pháp và self attention để trích xuất thông tin ngữ nghĩa.

Hơn nữa, để chứng minh tính hiệu quả của NADS framework, tác giả áp dụng NADS của mình cho BERT-SPC, AEN+BERT và DualGCN+BERT.

5.3 Implementation Details

Tác giả sử dụng bert-base-uncased English version. Sau DualGCN (Li et al., 2021), tác giả sử dụng LAL-Parser (Mrini et al., 2019) để lấy dependency tree cho DualGCN+NADS. Tác giả khởi tạo ngẫu nhiên embedding của ba cảm xúc và đặt $\lambda_1 = 0.4, \lambda_2 = 0.1$ trong quá trình training của tác giả. Các different margin ($m(pos, neu), m(pos, neg)$) được đặt thành (0.4, 0.6), (0.4, 0.6) cho bộ dữ liệu laptop và restaurant cho NADS framework của tác giả. Trong quá trình training, tác giả sử dụng AdamW làm optimizer và đặt learning rate thành 2×10^{-5} . Tác giả training model lên đến 15 epochs với batch size là 16.

5.4 Comparison Results

Tác giả sử dụng accuracy và macro-averaged F1-score để đánh giá tác vụ ABSA. Để dự đoán tốt hơn cảm xúc chính xác trong test, tác giả áp dụng ba cách khác nhau để test NADS framework.

- 1) **Original test:** sử dụng kết hợp của original aspect và original sentence làm đầu vào và trích xuất embedding để dự đoán.
- 2) **Noasp test:** sử dụng kết hợp của “< aspect >” và no-aspect template làm đầu vào của bộ mã hóa. Phương pháp test này có thể giúp chúng ta đánh giá liệu mô hình có thể dự đoán chính xác cảm xúc mà không cần biết ý nghĩa cụ thể của khía cạnh đó như con người hay không.
- 3) **Unite test:** sử dụng cả Original test mode và Noasp test mode để lấy scores của từng label cho mỗi cặp sentence-aspect và tổng scores của cùng một label sau khi chuẩn hóa.

Bảng 2 cho thấy các kết quả thực nghiệm chính của tác giả. Như chúng ta có thể thấy, NADS framework của tác giả vượt trội hơn tất cả baselines về laptop và restaurant datasets, hiệu suất của ba mô hình truyền thống: BERT-SPC, AEN+BERT và DualGCN+BERT đã được cải thiện sau khi thêm NADS framework. NADS của tác giả hoạt động tốt hơn BERT-SPC 3.03%/3.13% trên Restaurant/Laptop. Kết quả chứng minh rằng NADS framework của tác giả sử dụng hiệu quả cách nhận thức của con người và đóng vai trò tốt hơn trong tác vụ ABSA. So với các phương pháp truyền thống, no-aspect template của tác giả loại bỏ sentiment bias về khía cạnh và học thêm thông tin về một nhóm sentence patterns, điều này có thể

Models	Strategy	14Rest		14Lap	
		Accuracy	Macro-F1	Accuracy	Macro-F1
CapsNet+BERT (Jiang et al., 2019)	Ori	85.09	77.75	78.21	73.34
BERT-ADD (Rietzler et al., 2020)	Ori	87.14	80.05	79.19	74.18
SDGCN-BERT (Zhao et al., 2020)	Ori	83.57	76.47	81.35	78.34
R-GAT+BERT (Wang et al., 2020)	Ori	86.60	81.35	78.21	74.07
DGEDT+BERT (Tang et al., 2020)	Ori	86.30	80.00	79.80	75.60
BERT-SPC (Song et al., 2019)	Ori	84.46	76.98	78.99	75.03
	Noasp	81.77	70.81	75.47	69.65
	Unite	84.45	77.40	78.16	73.06
	Ori	87.49	82.09	82.12	79.13
	Noasp	87.04	81.77	81.01	77.69
	Unite	87.58	81.73	81.96	78.87
AEN+BERT (Song et al., 2019)	Ori	83.12	73.76	79.93	76.31
	Noasp	80.70	68.86	77.06	72.41
	Unite	80.97	71.65	78.16	74.39
AEN+NADS	Ori	84.00	75.88	81.33	77.78
	Noasp	86.51	80.16	80.22	76.88
	Unite	86.68	79.69	81.48	78.07
DualGCN+BERT (Li et al., 2021)	Ori	87.13	81.16	81.80	78.10
	Noasp	81.95	72.42	77.53	73.49
	Unite	84.90	77.24	78.64	74.43
DualGCN+NADS	Ori	87.49	82.07	82.75	79.95
	Noasp	86.86	81.23	81.49	78.02
	Unite	87.67	82.59	82.75	79.72

Bảng 2: Comparison of our NADS on three traditional methods to other baselines on two datasets.

làm giảm nhiễu do sentiment bias khía cạnh gây ra và tăng cường robustness cho framework của tác giả. Hơn nữa, differential sentiment loss của tác giả có thể phân loại cảm xúc tốt hơn thông qua việc phân biệt sự khác biệt trong ba trạng thái cảm xúc khác nhau này sau khi contrastive learning. Các thực nghiệm trên ba phương pháp truyền thống cũng cho thấy rằng framework của tác giả rất phù hợp với hầu hết các mô hình hiện có và tăng hiệu suất của chúng.

Song song đó, theo kết quả thực nghiệm của Noasp test, hiệu suất của các phương pháp truyền thống giảm xuống đáng kể mà không cần biết khía cạnh là gì. Tuy nhiên, NADS framework của tác giả vẫn có thể hoạt động tốt mà không cần biết khía cạnh giống như con người. Trong Noasp test mode, BERT-SPC giảm 2.69%/3.52% trên Restaurant/Laptop. Ngược lại, NADS framework của tác giả chỉ giảm 0.45%/1.11% trên Restaurant/Laptop. Tác giả cũng nhận thấy AEN+NADS tăng 2.51% trên tập dữ liệu Restaurant, trong khi AEN+BERT giảm 2.42%. Điều này cho thấy NADS của tác giả vẫn có thể hoạt động tốt mà không cần biết ý nghĩa

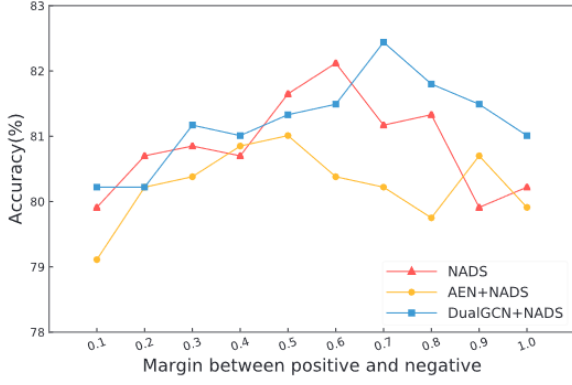
Models	14Rest		14Lap	
	Acc	Macro-F1	Acc	Macro-F1
NADS	87.49	82.09	82.12	79.13
NADS w/o NOASP	85.22	78.88	79.43	75.30
NADS w/o MAP	87.04	81.73	81.18	78.51
NADS w/o DS	87.22	81.71	81.01	77.26

Bảng 3: Experimental results of ablation study.

cụ thể của khía cạnh. So sánh ba test mode này, chúng ta cũng có thể thấy rằng Unite test mode có thể đạt được kết quả ổn định nhất trong các mô hình khác nhau.

5.5 Ablation Study

Để nghiên cứu sâu hơn vai trò của different modules trong framework của mình, tác giả tiến hành extensive ablation experiments. Kết quả được thể hiện trong Bảng 3. NADS w/o NOASP biểu thị rằng tác giả chỉ sử dụng original sentence và loại bỏ contrastive learning. Nếu không có phương pháp contrastive learning giữa no-aspect template và original sentence, sentiment bias của khía cạnh sẽ làm rối loạn kết quả dự đoán và quan trọng hơn, differential sentiment loss sẽ không hoạt động vì



Hình 4: Effect of different $m(pos, neg)$ while set $m(pos, neu) = 0.4$ in laptop dataset.


anisotropic trong mô hình BERT. Do đó, hiệu suất của nó bị suy giảm trên cả hai tập dữ liệu. NADS w/o MAP có nghĩa là tác giả loại bỏ masked aspect prediction module do đó chúng ta có thể mất thông tin ngữ nghĩa ban đầu của câu. NADS w/o DS chỉ ra rằng tác giả sử dụng cross-entropy loss function thay vì differential sentiment loss. Nếu không có differential sentiment loss, mô hình không thể tìm thấy khoảng cách khác nhau giữa các cảm xúc. Các thực nghiệm cho thấy rằng mọi module đều không thể thiếu trong NADS framework của tác giả.

5.6 Selection of Margin

Tác giả thực nghiệm với các different margin trong differential sentiment loss. Trong framework của mình, tác giả chỉ xem xét $m(pos, neu)$ và $m(pos, neg)$. Hình 4 cho thấy accuracy của different $m(pos, neg)$ khi tác giả đặt $m(pos, neu) = 0.4$ trong ba phương pháp của tác giả dựa trên NADS framework trên Laptop dataset. Như chúng ta thấy, đầu tiên accuracy tăng và sau đó giảm dần trong quá trình $m(pos, neg)$ tăng dần. Ba mô hình hoạt động tốt nhất khi $m(pos, neg)$ được đặt thành 0.6, 0.5 và 0.7. Thực nghiệm này cho thấy khoảng cách giữa positive và negative thực sự xa hơn khoảng cách giữa positive và neutral. Nó chứng tỏ hiệu quả của differential sentiment loss.

5.7 Sentiment Bias Elimination

Để hiểu rõ hơn về khả năng của NADS framework trong việc loại bỏ sentiment bias, tác giả tìm thấy một số ví dụ có nhãn là neutral và hiển thị kết quả dự đoán của chúng trong các mô hình khác nhau ở Bảng 4, trong đó P, N, O đại diện cho các cảm xúc positive, negative và neutral. Tác giả highlight các aspect word bằng màu đỏ. Chúng ta có thể thấy rằng NADS framework của tác giả vượt trội hơn tất



Hình 5: Distribution of bad cases of our NADS framework and BERT-SPC.

cả các mô hình khác. Đối với khía cạnh “steak” trong ví dụ đầu tiên, các phương pháp trước đây bỏ qua positive sentiment bias của “steak” và dự đoán không chính xác cảm xúc là positive. Ngược lại, NADS của tác giả loại bỏ positive sentiment bias thông qua no-aspect template và dự đoán cảm xúc chính xác là neutral. Hơn nữa, tác giả cũng chỉ ra sự phân bố các trường hợp xấu trong Hình 5. Các trường hợp xấu của các neutral aspect term trong NADS framework của tác giả ít hơn đáng kể so với BERT-SPC. Điều này chứng minh hiệu quả của NADS framework của tác giả trong việc loại bỏ sentiment bias. Tuy nhiên, vẫn có một số neutral aspect term trong framework được dự đoán không chính xác như được trình bày trong Bảng 4. Một lý do có thể là có những từ khác trong một câu mang sentiment bias ngoài khía cạnh hiện tại.

5.8 Robustness Study

Để xác minh robustness của NADS, tác giả kiểm tra robustness score của framework trên Aspect Robustness Test Set (ARTS) (Xing et al., 2020). Bộ dữ liệu làm phong phú thêm 14Lap và 14Res theo ba chiến lược: reverse the original sentiment of the target aspect (REVTGT), perturb the sentiments of the non-target aspects (REVNON) và generate more non-target aspect terms that have opposite sentiment polarities to the target (ADDDIFF). Họ lấy original sentence và ba variants làm unit. Chỉ khi original sentence và tất cả variants đều đúng, thì unit mới đúng. Tính accuracy của các unit trong bộ dữ liệu dưới dạng Aspect Robustness Score (ARS) cuối cùng.

Tác giả so sánh ARS của ba mô hình trước và sau khi thêm NADS framework. Kết quả trong Bảng 5 cho thấy ARS của mô hình đã được cải

#	Case	BERT-SPC	AEN+BERT	DualGCN+BERT	NADS
1	I asked for a simple medium rare steak .	(P _×)	(P _×)	(P _×)	(O _✓)
2	Desserts include flan and sopaipillas .	(P _× , P _× , P _×)	(P _× , P _× , P _×)	(P _× , P _× , P _×)	(O _✓ , P _× , P _×)
3	We started with the scallops and asparagus and also had the soft shell crab as well as the cheese plate .	(O _✓ , P _× , P _× , P _×)	(P _× , P _× , P _× , P _×)	(O _✓ , O _✓ , P _× , P _×)	(O _✓ , O _✓ , O _✓ , P _×)
4	Try the rose roll (not on menu).	(N _×)	(N _×)	(O _✓)	(O _✓)
5	There was only one waiter for the whole restaurant upstairs.	(N _×)	(N _×)	(O _✓)	(O _✓)

Bảng 4: Case study. Comparison of our NADS model to different baselines. Marker ✓ indicates correct prediction while × indicates incorrect prediction.

Models	Rest	Lap
	Acc → ARS(Change)	Acc → ARS(Change)
BERT-PT	86.70→59.29(↓27.41)	78.53→53.29(↓25.24)
RGAT	84.41→56.54(↓27.87)	78.08→51.37(↓26.72)
BERT-SPC	83.04→54.82(↓28.22)	77.59→50.94(↓26.65)
NADS	87.49→64.55(↓22.94)	82.12→58.77(↓23.35)
AEN+BERT	83.12→25.45(↓57.67)	79.93→30.09(↓49.84)
AEN+NADS	84.00→26.61(↓57.39)	81.33→37.15(↓44.18)
DualGCN+BERT	87.13→63.57(↓23.56)	81.80→57.99(↓23.81)
DualGCN+NADS	87.49→66.16(↓21.33)	82.75→60.82(↓21.93)

Bảng 5: Our NADS performance on aspect robustness test set. We compare the accuracy on original and the new test sets, and calculate the change of accuracy.

thiện đáng kể sau khi thêm NADS framework của tác giả. DualGCN+NADS hoạt động tốt hơn đáng kể so với các mô hình khác với mức giảm 21.33% và 21.93% trên Restaurant và Laptop. Điều này cho thấy rằng framework của tác giả sử dụng nhận thức của con người có robustness tốt hơn so với các mô hình khác.

Hơn nữa, tác giả sử dụng ba test mode để test trên ARTS như được hiển thị trong Bảng 6. Chúng ta có thể thấy, mô hình AEN+NADS với mức giảm 57.39% và 44.18% trên Restaurant và Laptop khi sử dụng Original test mode. Tuy nhiên, với mức giảm 26.51% và 22.34% khi sử dụng Noasp test mode. Trong overall scheme, Noasp test mode và Unite test mode có thể nhận được kết quả ổn định hơn so với Original test mode trên ARTS. Sử dụng no-aspect template trong thực nghiệm có thể là một phương pháp robustness test ổn định hơn.

6 Conclusion

Trong bài báo này, tác giả đề xuất một NADS framework phù hợp hơn với nhận thức của con người đối với tác vụ ABSA. NADS framework của tác giả sử dụng phương pháp no-aspect contrastive learning để loại bỏ sentiment bias về các khía cạnh và enhance the sentence representations. Ngoài ra, tác giả xây dựng differential sentiment loss để phân loại cảm xúc tốt hơn thông qua việc

Models	Strategy	Rest	Lap
		Acc→ARS(Change)	Acc→ARS(Change)
NADS	Ori	87.49→64.55(↓22.94)	82.12→58.77(↓23.35)
	Noasp	87.04→64.38(↓22.66)	81.01→59.56(↓21.35)
	Unite	87.58→64.91(↓22.67)	81.96→60.19(↓21.77)
AEN+NADS	Ori	84.00→26.61(↓57.39)	81.33→37.15(↓44.18)
	Noasp	86.51→60.00(↓26.51)	80.22→57.88(↓22.34)
	Unite	86.68→56.34(↓30.34)	81.48→50.78(↓30.70)
DualGCN+NADS	Ori	87.49→66.16(↓21.33)	82.75→60.82(↓21.93)
	Noasp	86.86→64.46(↓22.40)	81.49→60.03(↓21.46)
	Unite	87.67→65.36(↓22.31)	82.75→60.66(↓22.09)

Bảng 6: Comparison of three test modes on aspect robustness test set.

phân biệt khoảng cách khác nhau giữa các trạng thái cảm xúc. Các thực nghiệm mở rộng cho thấy rằng NADS framework thúc đẩy ba phương pháp ABSA điển hình và vượt trội hơn các baseline. Hơn nữa, NADS framework vẫn có thể hoạt động tốt ngay cả khi chúng ta không biết khía cạnh đó là gì. Thực nghiệm trên robustness dataset cho thấy rằng NADS framework của tác giả cải thiện đáng kể robustness của mô hình.

Tài Liệu Tham Khảo

Junqi Dai, Hang Yan, Tianxiang Sun, Pengfei Liu, and Xipeng Qiu. 2021. [Does syntax matter? a strong baseline for aspect-based sentiment analysis with RoBERTa](#). In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 1816–1829, Online. Association for Computational Linguistics.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. [BERT: Pre-training of deep bidirectional transformers for language understanding](#). In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.

Gamaleldin Elsayed, Dilip Krishnan, Hossein Mobahi, Kevin Regan, and Samy Bengio. 2018. Large mar-

- gin deep networks for classification. *Advances in neural information processing systems*, 31.
- Andrea Esuli and Fabrizio Sebastiani. 2006. Sentiwordnet: A publicly available lexical resource for opinion mining. In *Proceedings of the Fifth International Conference on Language Resources and Evaluation (LREC'06)*.
- Feifan Fan, Yansong Feng, and Dongyan Zhao. 2018. [Multi-grained attention network for aspect-level sentiment classification](#). In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 3433–3442, Brussels, Belgium. Association for Computational Linguistics.
- Jimin Hong, TaeHee Kim, Hyesu Lim, and Jaegul Choo. 2021. [AVocaDo: Strategy for adapting vocabulary to downstream domain](#). In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 4692–4700, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.
- Xiaochen Hou, Peng Qi, Guangtao Wang, Rex Ying, Jing Huang, Xiaodong He, and Bowen Zhou. 2021. [Graph ensemble learning over multiple dependency trees for aspect-level sentiment classification](#). In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2884–2894, Online. Association for Computational Linguistics.
- Binxuan Huang, Yanglan Ou, and Kathleen M Carley. 2018. Aspect level sentiment classification with attention-over-attention neural networks. In *International conference on social computing, behavioral-cultural modeling and prediction and behavior representation in modeling and simulation*, pages 197–206. Springer.
- Po-Sen Huang, Huan Zhang, Ray Jiang, Robert Stanford, Johannes Welbl, Jack Rae, Vishal Maini, Dani Yogatama, and Pushmeet Kohli. 2020. [Reducing sentiment bias in language models via counterfactual evaluation](#). In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 65–83, Online. Association for Computational Linguistics.
- Long Jiang, Mo Yu, Ming Zhou, Xiaohua Liu, and Tiejun Zhao. 2011. [Target-dependent Twitter sentiment classification](#). In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, pages 151–160, Portland, Oregon, USA. Association for Computational Linguistics.
- Qingnan Jiang, Lei Chen, Ruifeng Xu, Xiang Ao, and Min Yang. 2019. [A challenge dataset and effective models for aspect-based sentiment analysis](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 6280–6285, Hong Kong, China. Association for Computational Linguistics.
- Bohan Li, Hao Zhou, Junxian He, Mingxuan Wang, Yiming Yang, and Lei Li. 2020. [On the sentence embeddings from pre-trained language models](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9119–9130, Online. Association for Computational Linguistics.
- Lishuang Li, Yang Liu, and AnQiao Zhou. 2018. [Hierarchical attention based position-aware network for aspect-level sentiment analysis](#). In *Proceedings of the 22nd Conference on Computational Natural Language Learning*, pages 181–189, Brussels, Belgium. Association for Computational Linguistics.
- Ruifan Li, Hao Chen, Fangxiang Feng, Zhanyu Ma, Xiaojie Wang, and Eduard Hovy. 2021. [Dual graph convolutional networks for aspect-based sentiment analysis](#). In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 6319–6329, Online. Association for Computational Linguistics.
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- Khalil Mrini, Franck Dernoncourt, Trung Bui, Walter Chang, and Ndapa Nakashole. 2019. Rethinking self-attention: An interpretable self-attentive encoder-decoder parser.
- Judea Pearl et al. 2000. Models, reasoning and inference. *Cambridge, UK: Cambridge University Press*, 19(2).
- Jeffrey Pennington, Richard Socher, and Christopher Manning. 2014. [GloVe: Global vectors for word representation](#). In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1532–1543, Doha, Qatar. Association for Computational Linguistics.
- Maria Pontiki, Dimitris Galanis, John Pavlopoulos, Harris Papageorgiou, Ion Androutsopoulos, and Suresh Manandhar. 2014. [SemEval-2014 task 4: Aspect based sentiment analysis](#). In *Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014)*, pages 27–35, Dublin, Ireland. Association for Computational Linguistics.
- Alexander Rietzler, Sebastian Stabinger, Paul Opitz, and Stefan Engl. 2020. [Adapt or get left behind: Domain adaptation through BERT language model finetuning for aspect-target sentiment classification](#). In *Proceedings of the 12th Language Resources*

- and Evaluation Conference, pages 4933–4941, Marseille, France. European Language Resources Association.
- James M Robins. 2003. Semantics of causal dag models and the identification of direct and indirect effects. *Oxford Statistical Science Series*, pages 70–82.
- Youwei Song, Jiahai Wang, Tao Jiang, Zhiyue Liu, and Yanghui Rao. 2019. Attentional encoder network for targeted sentiment classification. *arXiv preprint arXiv:1902.09314*.
- Xingwei Tan, Yi Cai, and Changxi Zhu. 2019. [Recognizing conflict opinions in aspect-level sentiment classification with dual attention networks](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3426–3431, Hong Kong, China. Association for Computational Linguistics.
- Duyu Tang, Bing Qin, Xiaocheng Feng, and Ting Liu. 2015. Effective lstms for target-dependent sentiment classification. *arXiv preprint arXiv:1512.01100*.
- Hao Tang, Donghong Ji, Chenliang Li, and Qiji Zhou. 2020. [Dependency graph enhanced dual-transformer structure for aspect-based sentiment classification](#). In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6578–6588, Online. Association for Computational Linguistics.
- Bo Wang, Tao Shen, Guodong Long, Tianyi Zhou, and Yi Chang. 2021. [Eliminating sentiment bias for aspect-level sentiment classification with unsupervised opinion extraction](#). In *Findings of the Association for Computational Linguistics: EMNLP 2021*, pages 3002–3012, Punta Cana, Dominican Republic. Association for Computational Linguistics.
- Kai Wang, Weizhou Shen, Yunyi Yang, Xiaojun Quan, and Rui Wang. 2020. [Relational graph attention network for aspect-based sentiment analysis](#). In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 3229–3238, Online. Association for Computational Linguistics.
- Xiaoyu Xing, Zhijing Jin, Di Jin, Bingning Wang, Qi Zhang, and Xuanjing Huang. 2020. [Tasty burgers, soggy fries: Probing aspect robustness in aspect-based sentiment analysis](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3594–3605, Online. Association for Computational Linguistics.
- Chen Zhang, Qiuchi Li, and Dawei Song. 2019. [Aspect-based sentiment classification with aspect-specific graph convolutional networks](#). In *Proceedings of the 2019 Conference on Empirical Methods*
- in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pages 4568–4578, Hong Kong, China. Association for Computational Linguistics.
- Zhilu Zhang and Mert Sabuncu. 2018. Generalized cross entropy loss for training deep neural networks with noisy labels. *Advances in neural information processing systems*, 31.
- Pinlong Zhao, Linlin Hou, and Ou Wu. 2020. Modeling sentiment dependencies with graph convolutional networks for aspect-level sentiment classification. *Knowledge-Based Systems*, 193:105443.